

Álgebra da Memória: Fundamentos Formais e Validação Empírica da Composição Associativa sem Interferência Catastrófica

Pedro Felipe Rodrigues de Farias¹

¹Pesquisador Independente

Setembro de 2026

Este trabalho está licenciado sob uma licença Creative Commons Attribution 4.0 International (CC BY 4.0).

Abstract

Proponho e valido um framework algébrico para composição de memória em sistemas de inteligência artificial que resolve o trade-off fundamental entre composicionalidade e preservação de representações. A álgebra da memória (V, G, T, P) estrutura memórias como objetos tipados compostos por embeddings semânticos (V), grafos relacionais (G), índices temporais (T) e pesos de utilidade (P), equipados com cinco operações: composição ($\oplus$), retração ($\ominus$), transformação ($\otimes$), recuperação (ρ) e poda (Π_C). Em vez de reivindicar superar a interferência catastrófica dentro de um estado vetorial de capacidade fixa, o framework estabelece uma decisão arquitetural explícita: a composição é formulada como coproduto (união disjunta) em uma categoria de estruturas relacionais atribuídas, garantindo associatividade exata por construção. O problema difícil da agregação de memória é deliberadamente diferido para o momento da consulta via operador quociente categórico sob demanda (ρ) baseado no fecho transitivo de uma relação de similaridade, enquanto limites de capacidade são governados de forma independente via poda (Π_C). Sob protocolo de estabilidade de composição sequencial, a álgebra é significativamente mais estável que uma LSTM não-treinada ($p = 1,48 \times 10^{-7}$, Mann-Whitney U unilateral) e soma vetorial ($p = 1,03 \times 10^{-6}$), mas não supera uma LSTM treinada em amostra ou um buffer kNN na métrica isolada de estabilidade vetorial. A Fase 3, portanto, avalia capacidades estruturais: a álgebra atinge 100% de acurácia em resolução de conflitos temporais (kNN: 50%), retração de fatos (kNN: 33–43%) e raciocínio relacional multi-hop (kNN: 87–93%). A Fase 4 valida a álgebra com embeddings reais de linguagem natural (all-MiniLM-L6-v2, 384 dimensões): associatividade exata preservada, recuperação semântica top-1 de 100% (20/20) com paráfrases e estabilidade sob composição sequencial. O framework escala até $N = 10^4$ memórias com latência de recuperação inferior a 500 ms em corpora operando abaixo do limiar de percolação ($\langle k \rangle < 1$, garantido via calibração por quantil empírico), fornecendo uma base algébrica principled para memória persistente e composicional em agentes de IA. Código completo e pacotes de replicação estão disponíveis em <https://github.com/pedrofariasx/memory-algebra> (DOI: 10.5281/zenodo.22815162).

Palavras-chave: álgebra da memória, interferência catastrófica, composição associativa, teoria das categorias, grafos de conhecimento, raciocínio temporal, revisão de crenças

1 Introdução

1.1 Motivação

Sistemas de memória contemporâneos para inteligência artificial—including redes neurais recorrentes, transformers com memória aumentada e esquemas de acumulação vetorial—sofrem de

interferência catastrófica: a diluição progressiva e a sobrescrita de representações previamente armazenadas à medida que novas observações são incorporadas [1, 2]. Este modo de falha representa um obstáculo fundamental para a construção de agentes autônomos de IA capazes de aprendizado contínuo, raciocínio de longo horizonte e modelagem consistente de mundo.

O obstáculo subjacente é algébrico e estrutural. A interferência catastrófica surge inexoravelmente sempre que uma arquitetura tenta agregar experiências sequenciais ilimitadas em um *estado paramétrico de capacidade fixa* (como um vetor oculto recorrente h_t ou centróide vetorial móvel). Em qualquer esquema de capacidade fixa, cada atualização é com perda e dependente da ordem de fusão: comprimir o estado inevitavelmente destrói distinções individuais. Inversamente, simplesmente anexar observações a uma lista plana de vetores preserva embeddings brutos, mas carece de estrutura composicional, garantias algébricas, resolução de conflitos temporais e raciocínio relacional.

Isso apresenta um dilema evidente: ou realizar agregação prematura e com perda em uma representação fixa sofrendo interferência, ou acumular dados desorganizados sem estrutura algébrica. Abordagens existentes ou aceitam a interferência como custo inevitável do aprendizado conexionista, ou recorrem a buffers ad-hoc de engenharia de prompt e recuperação plana em bancos vetoriais.

1.2 Contribuição

Proponho uma alternativa principled: uma *álgebra da memória* que resolve este dilema por meio de uma separação explícita de responsabilidades. Em vez de postular um milagre empírico que comprima memória em um único vetor de tamanho fixo sem perda de informação, a álgebra adota uma decisão arquitetural deliberada:

1. **Composição como Coproduto:** A composição ($\oplus$) é formulada como o coproduto categórico (união disjunta) na categoria de estruturas relacionais atribuídas **Mem**. Isso garante associatividade exata e independente de ordem por construção, preservando cada tupla de memória atômica sem perdas.
2. **Agregação Semântica Diferida:** O problema computacionalmente complexo e potencialmente destrutivo da agregação semântica (identificar conceitos idênticos ou quase-sinônimos) é deliberadamente diferido do momento da escrita para o momento da consulta. Ele é realizado sob demanda via quociente categórico (coequalizador) sob o fecho transitivo de uma relação de similaridade semântica R_θ .
3. **Gestão de Capacidade Desacoplada:** A capacidade finita de memória não é acoplada à composição, mas governada de forma independente por um operador explícito de poda Π_C , assegurando estabilidade sem corromper as leis algébricas.

A álgebra da memória (V, G, T, P) satisfaz simultaneamente cinco desideratos fundamentais:

- A Associatividade:** $(m_1 \oplus m_2) \oplus m_3 \cong m_1 \oplus (m_2 \oplus m_3)$
- B Recuperabilidade:** $d_s(m, \rho(M, q)) \rightarrow 0$ para qualquer memória armazenada m na ausência de interferência destrutiva
- C Estabilidade:** $\|M_t\| \leq C$ sob política de poda Π_C
- D Preservação:** $\otimes$ não destrói a estrutura recuperável (functorialidade)
- E Eficiência:** Operações tratáveis sobre representações relacionais discretas

Nossas contribuições são quatro:

1. Um framework algébrico formal fundamentado em teoria das categorias (estruturas relacionais atribuídas, coprodutos e quocientes coequalizadores) com prova de associatividade verificável computacionalmente.
2. Posicionamento profundo das operações de memória na literatura seminal de IA, estabelecendo a retração ($\ominus$) como realização operacional da contração de crenças sob os postulados AGM [3], conectando o rastreamento relacional aos Sistemas de Manutenção da Verdade (TMS) [6, 7], e ancorando consultas temporais a Grafos de Conhecimento Temporais [8, 9, 10].
3. Validação empírica abrangente em 50 seeds, varreduras de parâmetros, condições adversariais e baselines competitivas com total transparência de métricas.
4. Diferenciação estrutural de baselines de busca aumentada (buffers kNN) em resolução de conflitos temporais, retração de fatos e raciocínio relacional multi-hop, validada com embeddings reais de sentence-transformers e agentes ReAct multi-modelo.

1.3 Organização do Artigo

A Seção 2 desenvolve o framework formal. A Seção 3 define as operações algébricas. A Seção 4 apresenta a prova de associatividade e esclarece sua natureza arquitetural. A Seção 5 reporta a validação empírica e comparação com baselines. A Seção 6 discute análise de percolação, limitações e posicionamento detalhado na literatura. A Seção 7 conclui.

2 Framework Formal

2.1 A Categoria de Objetos de Memória

Para estabelecer uma fundamentação matematicamente rigorosa, formalizamos memórias na linguagem da teoria das categorias, definindo a categoria **Mem** de estruturas relacionais tipadas atribuídas.

Definição 2.1 (Objeto de Memória). Um objeto $M \in \mathbf{Mem}$ é uma tupla $M = (N, v, E, \tau, w)$ onde:

- N é um conjunto finito de identificadores de nós atômicos;
- $v : N \rightarrow V = \mathbb{R}^d$ é um atributo de embedding que mapeia cada nó a um vetor denso no espaço semântico;
- $E \subseteq N \times N \times L$ é um conjunto de arestas direcionadas rotuladas, onde L é um alfabeto finito de rótulos relacionais;
- $\tau : N \rightarrow T = (\mathbb{R}_{\geq 0}, \leq)$ é um atributo temporal que associa cada nó a um timestamp contínuo em uma linha temporal ordenada;
- $w : N \rightarrow P = [0, 1]$ é um atributo de peso de utilidade representando prioridade de retenção no semiring idempotente $([0, 1], \max, \cdot, 0, 1)$.

Definição 2.2 (Morfismos de Memória). Dados objetos $M_1 = (N_1, v_1, E_1, \tau_1, w_1)$ e $M_2 = (N_2, v_2, E_2, \tau_2, w_2)$, um morfismo $f : M_1 \rightarrow M_2$ em **Mem** é uma função injetiva de conjuntos $f_N : N_1 \rightarrow N_2$ que preserva toda a estrutura relacional e de atributos:

1. $v_2(f_N(u)) = v_1(u)$ para todo $u \in N_1$ (preservação do embedding semântico);
2. $(u, v, l) \in E_1 \implies (f_N(u), f_N(v), l) \in E_2$ (preservação das relações direcionadas rotuladas);

3. $\tau_2(f_N(u)) = \tau_1(u)$ para todo $u \in N_1$ (preservação de timestamps);
4. $w_2(f_N(u)) = w_1(u)$ para todo $u \in N_1$ (preservação de pesos de utilidade).

A composição de morfismos é a composição padrão de funções dos mapeamentos de nós subjacentes, e os morfismos identidade são funções identidade nos conjuntos de nós. Assim, **Mem** forma uma categoria bem-definida.

2.2 Composição como Coproduto e Quociente Semântico Diferido

Por que a composição ingênua não é associativa? Em um modelo ingênuo de pushout ou fusão prematura, quando duas memórias m_1 e m_2 são compostas, nós cuja similaridade cosseno excede um limiar θ são fundidos prematuramente por média de seus embeddings: $\bar{v} = \frac{1}{2}(v_a + v_b)$. No entanto, a média de centroides vetoriais é fundamentalmente não-associativa:

$$\frac{1}{2} \left(\frac{1}{2}(v_a + v_b) + v_c \right) = \frac{1}{4}v_a + \frac{1}{4}v_b + \frac{1}{2}v_c \neq \frac{1}{2}v_a + \frac{1}{4}v_b + \frac{1}{4}v_c = \frac{1}{2} \left(v_a + \frac{1}{2}(v_b + v_c) \right).$$

Além disso, a similaridade por limiar em pares é não-transitiva: $\cos(v_a, v_b) \geq \theta$ e $\cos(v_b, v_c) \geq \theta$ não implicam $\cos(v_a, v_c) \geq \theta$. Fundir nós prematuramente gera severa dependência da ordem de avaliação: agrupar $(m_1 \oplus m_2) \oplus m_3$ produz centroides de cluster e topologias de arestas distintas de $m_1 \oplus (m_2 \oplus m_3)$.

Para resolver isso, nossa arquitetura separa estritamente a composição estrutural da fusão semântica:

Definição 2.3 (Composição como Coproduto). A composição $M_1 \oplus M_2$ é o coproduto categórico $M_1 \sqcup M_2$ em **Mem**:

$$M_1 \oplus M_2 = (N_1 \sqcup N_2, v_1 \sqcup v_2, E_1 \sqcup E_2, \tau_1 \sqcup \tau_2, w_1 \sqcup w_2),$$

onde os conjuntos de nós são tornados disjuntos por prefixação única de namespace ($N_1 \sqcup N_2 = (\{1\} \times N_1) \cup (\{2\} \times N_2)$), e os mapeamentos de atributos e relações de arestas são as uniões disjuntas canônicas de seus respectivos componentes.

Como coprodutos em categorias concretas de estruturas atribuídas são associativos a menos de isomorfismo natural, a composição é associativa por construção: $(M_1 \oplus M_2) \oplus m_3 \cong M_1 \oplus (M_2 \oplus M_3)$.

Definição 2.4 (Quociente Semântico como Coequalizador Categórico). A agregação semântica é derivada sob demanda no momento da recuperação. Para qualquer objeto de memória $M = (N, v, E, \tau, w)$ e limiar de similaridade $\theta \in [-1, 1]$, define-se a relação reflexiva e simétrica de similaridade $R_\theta \subseteq N \times N$:

$$(u, w) \in R_\theta \iff \cos(v(u), v(w)) \geq \theta.$$

Seja $\sim_\theta = R_\theta^*$ o fecho transitivo de R_θ , que é a menor relação de equivalência contendo R_θ . O quociente semântico $M / \sim_\theta$ é o coequalizador categórico do par de relações $(R_\theta \rightrightarrows N)$. O objeto quociente possui conjunto de nós $N / \sim_\theta$ (classes de equivalência $[u]$), onde cada cluster $[u]$ recebe:

- Embedding centroide canônico: $\bar{v}_{[u]} = \frac{1}{|[u]|} \sum_{x \in [u]} v(x)$;
- Timestamp efetivo: $\bar{\tau}_{[u]} = \max_{x \in [u]} \tau(x)$;
- Prioridade efetiva: $\bar{w}_{[u]} = \max_{x \in [u]} w(x)$;
- Arestas do quociente: $([u], [w], l) \in E / \sim_\theta \iff \exists x \in [u], y \in [w] : (x, y, l) \in E$.

Ao computar o fecho transitivo simultaneamente sobre todos os nós atômicos acumulados, o quociente depende exclusivamente do conjunto total de nós atômicos e seus embeddings, sendo completamente independente da ordem cronológica ou dos parênteses sob os quais as memórias foram compostas.

2.3 Distância Semântica Híbrida e Racional dos Pesos

Para quantificar a distância semântica entre objetos de memória, definimos uma métrica híbrida fundamentada em **Mem**:

Definição 2.5 (Distância Semântica Híbrida). Para objetos de memória $m_1, m_2 \in \mathbf{Mem}$, a distância semântica híbrida é:

$$d_s(m_1, m_2) = \alpha d_V + \beta d_G + \gamma d_T + \delta d_P, \quad \text{com } \alpha + \beta + \gamma + \delta = 1, \quad \alpha, \beta, \gamma, \delta \geq 0$$

onde:

- $d_V = 1 - \cos(\bar{v}_1, \bar{v}_2) \in [0, 2]$ é a distância cosseno entre embeddings médios dos nós $\bar{v}_i = \frac{1}{|N_i|} \sum_{u \in N_i} v_i(u)$ (ou 1,0 se vazio);
- $d_G = \frac{1}{2}(1 - J(N_1, N_2)) + \frac{1}{2}(1 - J(E_1, E_2)) \in [0, 1]$ é a distância estrutural, computada via distância de Jaccard $1 - J(A, B) = \frac{|A \triangle B|}{|A \cup B|}$ sobre nós e arestas;
- $d_T = \frac{|\bar{\tau}_1 - \bar{\tau}_2|}{1 + |\bar{\tau}_1 - \bar{\tau}_2|} \in [0, 1]$ é a distância temporal limitada entre timestamps médios;
- $d_P = |\bar{w}_1 - \bar{w}_2| \in [0, 1]$ é a diferença absoluta entre pesos médios de utilidade.

A configuração padrão de pesos é $(\alpha, \beta, \gamma, \delta) = (0,40; 0,30; 0,15; 0,15)$.

Justificativa dos Pesos da Métrica: A escolha dos pesos padrão reflete uma hierarquia funcional fundamentada:

1. **Alinhamento semântico vetorial** ($\alpha = 0,40$): A similaridade semântica carrega o maior peso individual porque em ambientes não-estruturados e tarefas de linguagem natural, a correspondência conceitual é o determinante primário de relevância. Se os conceitos semânticos não se alinham, coincidências estruturais ou temporais são irrelevantes.
2. **Fidelidade estrutural relacional** ($\beta = 0,30$): A topologia relacional constitui o segundo pilar. Arestas relacionais representam asserções factuais (ex.: ligações sujeito-predicado-objeto). Preservar a estrutura do grafo previne associação incorreta entre entidades e assegura a retenção do contexto relacional.
3. **Moduladores Temporal** ($\gamma = 0,15$) **e de Utilidade** ($\delta = 0,15$): As métricas temporal e de prioridade atuam como moduladores calibrados em vez de seletores primários. O peso de 0,15 assegura que diferenças temporais e níveis de utilidade possam desempatar fatos semanticamente idênticos (ex.: resolver atualizações temporais entre fatos concorrentes) sem distorcer ou ofuscar a relevância semântica autêntica.

Nota de Sensibilidade e Adaptação ao Contexto: A métrica de distância é estável sob pequenas perturbações de pesos ($\pm 0,05$). Além disso, a álgebra suporta pesos dinâmicos adaptativos ao contexto (`context_weights`):

- Para *consultas ancoradas no tempo*, até 0,15 é transferido de α para γ , resultando em $(\alpha, \beta, \gamma, \delta) = (0,25; 0,30; 0,30; 0,15)$.
- Para *consultas estruturais de grafo*, até 0,15 é transferido de α para β , resultando em $(\alpha, \beta, \gamma, \delta) = (0,25; 0,45; 0,15; 0,15)$.

Em todos os casos, a normalização no simplex $\sum = 1$ é estritamente preservada.

3 Operações Algébricas

3.1 Composição ($\oplus$)

Como formalizado na Seção 2, a composição é o coproduto categórico:

1. $m_1 \oplus m_2 = m_1 \sqcup m_2$ é a *união disjunta* das tuplas atômicas. Nenhuma informação é perdida, comprimida ou agregada no momento da composição.
2. A relação de fusão $R_\theta = \{(a, b) : \cos(v_a, v_b) \geq \theta\}$ é definida exclusivamente sobre nós atômicos.
3. A partição de fusão é $\pi = R_\theta^*$ (fecho transitivo), computada via union-find sob demanda para recuperação.

3.2 Retração ($\ominus$)

A retração remove conhecimento obsoleto ou invalidado: $M \ominus m_i$ remove todos os nós de m_i e arestas incidentes de M , e aplica projeção ortogonal para eliminar influência residual nos vetores. Conforme discutido na Seção 6, este operador fornece uma realização computacional da contração de crenças sob os postulados AGM [3].

3.3 Transformação ($\otimes$)

A transformação aplica um operador linear W aos vetores e renomeia arestas: $\otimes_W(M) = (N, Wv, E', \tau, w)$. Para W ortogonal, a recuperação é invariante (functorialidade): $\rho \circ \otimes_W = \otimes_W \circ \rho$.

3.4 Recuperação (ρ)

A recuperação computa o quociente categórico M/π , pontua cada cluster c por:

$$s(c) = \max(\cos(q_v, \bar{v}_c), 0) \cdot f_T(c) \cdot (0,5 + 0,5 w_c)$$

onde $f_T(c) = e^{-((t_c - t_q)/\sigma)^2}$ fornece ancora temporal contínua. Os k clusters de maior score são selecionados e expandidos h saltos via BFS no grafo quociente.

3.5 Poda (Π_C)

O operador de poda impõe capacidade limitada de forma independente da composição:

1. **Esquecimento por utilidade:** Remove nós com $w(n) < \varepsilon$.
2. **Compressão de caminhos:** Para $u \rightarrow b \rightarrow v$ com b removido, insere atalho $u \rightarrow v$.
3. **Teto de capacidade:** Se $|N| > C$, remove nós de menor w até $|N| = C$.

4 Prova de Associatividade

4.1 Decisão Arquitetural vs. Compressão em Capacidade Fixa

Abordamos diretamente uma questão fundamental: a associatividade é uma descoberta empírica milagrosa que resolve a interferência catastrófica em capacidade fixa, ou é uma decisão arquitetural de design?

Trata-se de uma decisão arquitetural de design explícita. Em arquiteturas conexistas e modelos paramétricos (como RNNs, LSTMs e transformers recorrentes), a interferência catastrófica surge porque armazenamento e agregação são forçados a ocorrer simultaneamente dentro de

um estado vetorial de capacidade fixa $h \in \mathbb{R}^d$. Quando uma nova observação x é incorporada via $h_t = f(Wh_{t-1} + Ux_t)$, representações anteriores são sobrescritas. Tentar tornar tal compressão de capacidade fixa associativa e ao mesmo tempo preservar recuperação exata é matematicamente impossível: a capacidade fixa impõe um gargalo de teoria da informação.

Na álgebra da memória, não alegamos ter comprimido históricos infinitos em um único vetor sem perda. Em vez disso, dissolvemos o problema da interferência no momento da escrita definindo a composição $\oplus$ como o coproduto (união disjunta) em **Mem**. O coproduto é associativo por construção porque a união disjunta é associativa em **Set** e em categorias de estruturas atribuídas.

O problema difícil da agregação de memória—identificar entidades idênticas, fundir sinônimos e consolidar fatos—não é ignorado; ele é *deliberadamente diferido* para o momento da consulta via operador quociente ρ , e os limites de capacidade são gerenciados independentemente pelo operador de poda Π_C . O custo computacional é transferido da escrita (onde a fusão destruiria a associatividade e perderia informação de forma irreversível) para a consulta (onde operam clusterização e travessia de grafos).

4.2 Teorema e Prova

Teorema 4.1 (Associatividade Exata). Para quaisquer três objetos de memória $m_1, m_2, m_3 \in \mathbf{Mem}$,

$$(m_1 \oplus m_2) \oplus m_3 \cong m_1 \oplus (m_2 \oplus m_3)$$

como objetos atômicos em **Mem**, e os objetos quocientes induzidos $((m_1 \oplus m_2) \oplus m_3)/\sim_\theta$ e $(m_1 \oplus (m_2 \oplus m_3))/\sim_\theta$ são estritamente isomorfos.

Proof. (i) Como $\oplus$ é o coproduto (união disjunta) sobre conjuntos de nós com identificadores unicamente prefixados, $(N_1 \sqcup N_2) \sqcup N_3 = N_1 \sqcup (N_2 \sqcup N_3)$ pela associatividade de $\sqcup$ em **Set**; idem para v , E , τ , w como uniões disjuntas de funções e relações com domínios disjuntos. Logo, os objetos atômicos coproduto são isomorfos.

(ii) A relação R_θ sobre o conjunto total $N = N_1 \sqcup N_2 \sqcup N_3$ depende apenas dos pares de vetores atômicos: $(u, w) \in R_\theta \iff \cos(v(u), v(w)) \geq \theta$. Como N e v são idênticos sob ambas as ordens de associação, a relação R_θ coincide estritamente. O fecho transitivo $\sim_\theta = R_\theta^*$ é único (a menor relação de equivalência contendo R_θ), portanto a partição π de classes de equivalência é idêntica.

(iii) Embeddings de cluster (média dos vetores membros), tempos efetivos (max), pesos (max) e arestas do quociente são funções determinísticas de (N, v, E, τ, w, π) , logo coincidem. ■ □

Esta prova foi independentemente verificada via ground truth categórico usando Catlab.jl (Julia), confirmando isomorfismo de pushout e coproduto: $((m_1 \oplus m_2) \oplus m_3) \cong (m_1 \oplus (m_2 \oplus m_3))$.

5 Validação Empírica

5.1 Configuração Experimental

Todos os experimentos utilizam embeddings sintéticos em $\mathbb{R}^d$ com estrutura de correlação controlada, além de embeddings reais de linguagem natural na Fase 4. O limiar de fusão é $\theta = 0,85$ salvo indicação contrária. Significância estatística é avaliada com testes Mann–Whitney U unilaterais, com hipótese alternativa de que a álgebra tem distância final de recuperação menor que a baseline. Código completo, dados brutos e ambientes de replicação estão disponíveis no repositório do projeto: <https://github.com/pedrofariasx/memory-algebra> (DOI Zenodo: 10.5281/zenodo.22815162). Os exemplos de recuperação exata do protocolo exploratório são casos determinísticos de baixa interferência; a Fase 2 reporta distâncias médias em sequências aleatórias.

5.2 Fase 2A: Robustez Estatística

5.2.1 Múltiplas Seeds ($S = 50$)

Métrica	Valor
Taxa de aprovação de associatividade	1,000 (50/50)
Distância máxima esq/dir (média $\pm$ dp)	$0,0 \pm 0,0$
Estabilidade final (média $\pm$ dp)	$0,478 \pm 0,132$
Estabilidade final (IC 95%)	[0,440; 0,516]

Table 1: A associatividade é *exata* ($d_{\max} = 0$) em todas as 50 seeds.

5.2.2 Sensibilidade a Parâmetros

A associatividade é *invariante* ao limiar de fusão $\theta \in [0,60; 0,95]$ e à dimensionalidade $d \in \{8, 16, 32, 64\}$, com taxa de aprovação = 1,0 e $d_{\max} = 0$ em todas as configurações. Isso é algebricamente esperado: R_{θ}^* é uma função determinística dos vetores, independente da ordem de composição.

5.2.3 Testes Adversariais

Teste	Seeds	Resultado
Vetores idênticos (colisão total)	10/10	Sem colapso, assinatura preservada
Vetores antiparalelos ($\cos = -1$)	10/10	Sem colapso, nós mantidos separados
Escala $N = 1000$	1	1953 nós, compose = 0,074s

Table 2: Nenhuma falha catastrófica sob condições adversariais.

5.3 Fase 2B: Realismo dos Embeddings

5.3.1 Conceitos Correlacionados (varredura de ρ)

ρ	Taxa de assoc.	Estabilidade (média $\pm$ dp)
0,00	1,0	$0,506 \pm 0,140$
0,20	1,0	$0,507 \pm 0,139$
0,40	1,0	$0,508 \pm 0,137$
0,60	1,0	$0,508 \pm 0,135$
0,80	1,0	$0,505 \pm 0,132$
0,95	1,0	$0,501 \pm 0,130$

Table 3: A associatividade permanece exata mesmo sob correlação extrema ($\rho = 0,95$).

A estrutura (G, T, P) protege os vetores da diluição independentemente do grau de correlação entre conceitos.

5.4 Fase 2C: Comparação com Baselines

A álgebra tem distância final significativamente menor que a LSTM não-treinada e a soma vetorial. Ela não supera a LSTM treinada nem o buffer kNN nessa métrica isolada de estabilidade: a LSTM

Método	Estabilidade final (média $\pm$ dp)	Mann–Whitney p
Álgebra (V, G, T, P)	$0,424 \pm 0,129$	—
LSTM (não-treinada)	$0,998 \pm 0,220$	$1,48 \times 10^{-7}$
LSTM (treinada, Adam 500 steps)	$0,0010 \pm 0,001$	$< 0,01$
Soma vetorial	$0,698 \pm 0,113$	$1,03 \times 10^{-6}$
kNN (busca aumentada)	$0,150 \pm 0,357$	0,9999

Table 4: Comparação de estabilidade após 50 composições sequenciais (20 seeds). Menor é melhor. Os valores de p são de Mann–Whitney U unilaterais para a hipótese de que a álgebra tem distância menor; valores próximos de 1 indicam que a baseline é menor.

treinada memoriza a sequência fixa sob o protocolo em amostra avaliado aqui (generalização não foi testada), e o buffer kNN retém o vetor da primeira memória em uma lista crescente. Portanto, estabilidade isolada é insuficiente para estabelecer a contribuição da álgebra; a Fase 3 avalia as operações estruturais que um buffer plano não fornece.

Transparência da Métrica de Avaliação para Baselines Vetoriais: Nas comparações com baselines, todas as arquiteturas de referência—LSTM não-treinada, LSTM treinada em amostra, soma vetorial e buffer kNN—produzem exclusivamente representações vetoriais (V). Nenhuma dessas baselines possui topologia de grafo relacional (G), timestamps temporais (T) ou pesos de utilidade (P). Consequentemente, a distância estrutural d_G , a distância temporal d_T e a distância de prioridade d_P são indefinidas para esses sistemas vetoriais. Para garantir total equidade e evitar penalizar baselines por dimensões que não modelam, as avaliações estatísticas de estabilidade reportadas na Tabela 4 e na Figura 1 são medidas **estritamente sobre o componente vetorial** $d_V = 1 - \cos(\bar{v}_1, \bar{v}_2)$ (o que corresponde a avaliar d_s com $\alpha = 1, 0, \beta = \gamma = \delta = 0, 0$). Para a álgebra da memória, a recuperação retorna um subobjeto cujo centroide agregado é comparado ao vetor da memória inicial sob d_V . A distância híbrida completa d_s é reservada para tarefas multi-modais (Fase 3), onde atributos relacionais, temporais e de prioridade são ativamente testados.

5.5 Fase 2D: Escalabilidade

N memórias	Nós totais	Compose (s)	Retrieve (s)	Status
100	196	0,000	0,014	OK
500	982	0,000	0,064	OK
1.000	1.953	0,001	0,172	OK
5.000	9.973	0,008	0,290	OK
10.000	19.986	0,011	0,478	OK

Table 5: Benchmark de escalabilidade com limite de memória de 4 GB por subprocesso.

Duas otimizações permitem escalar a $N = 10^4$ dentro do limite de 4 GB: (i) *LSH encadeado* — buckets com mais de 64 elementos geram apenas pares consecutivos $O(n)$ em vez de enumeração $O(n^2)$; (ii) *compose_all* — composição em lote $O(N)$ em vez de composição sequencial com cópia integral a cada passo. Retrieve em $N = 10^4$: 0,478 s (< 1 s).

5.6 Fase 3: Diferenciação Estrutural do kNN

A Fase 2 revelou que, em estabilidade absoluta, a álgebra não se diferencia estatisticamente de um buffer kNN simples ($p = 0,9999$). A Fase 3 testa cenários onde o kNN *falha estruturalmente*:




Figure 1: Distância média de recuperação da primeira memória em função do passo de composição (50 composições, 20 seeds). Menor é melhor.

Experimento	Álgebra	kNN	Diferenciação
Conflito temporal ($\rho = 0,0$)	60/60 (100%)	30/60 (50%)	$\Delta = 50\%$
Conflito temporal ($\rho = 0,8$)	60/60 (100%)	30/60 (50%)	$\Delta = 50\%$
Retração de fatos ($\rho = 0,0$)	30/30 (100%)	13/30 (43%)	$\Delta = 57\%$
Retração de fatos ($\rho = 0,8$)	30/30 (100%)	10/30 (33%)	$\Delta = 67\%$
Multi-hop + distratores ($\rho = 0,0$)	30/30 (100%)	26/30 (87%)	$\Delta = 13\%$
Multi-hop + distratores ($\rho = 0,8$)	30/30 (100%)	28/30 (93%)	$\Delta = 7\%$

Table 6: Diferenciação da Fase 3. Cada experimento usa 30 seeds independentes sob condições ortogonal ($\rho = 0$) e correlacionada ($\rho = 0,8$).

5.6.1 Resolução de Conflitos Temporais

A álgebra usa ponderação temporal $f_T(c) = e^{-((t_c - t_q)/\sigma)^2}$ para preferir fatos recentes; o kNN é temporalmente cego, atingindo exatamente o nível de chance (50%).

5.6.2 Retração de Fatos

A álgebra remove fatos obsoletos via $\ominus$; o kNN retém todos os fatos em seu buffer, retornando fatos retraídos em 57–67% das tentativas.

5.6.3 Raciocínio Multi-hop

A álgebra percorre arestas relacionais (hops = 3) para alcançar nós distantes; o kNN depende de similaridade vetorial top- k sem travessia relacional.

5.6.4 Ablação contra Baselines de Produção

Para estabelecer com honestidade em que consiste a vantagem estrutural da álgebra, ablacionamos as tarefas da Fase 3 contra duas baselines de produção com capacidades não-algébricas equivalentes: um **ProductionVectorDB** (banco vetorial com metadados de timestamp e deleção física) e um **SQLiteTripleStore** (banco de triplas relacional consultado com common table expressions recursivas, CTE). Esta ablação isola qual capacidade—metadados, estrutura de grafo ou sua combinação—conduz cada tarefa.

Capacidade testada	Álgebra	VectorDB	SQLite CTE
Conflito temporal (timestamp)	100%	100%	—
Travessia multi-hop (grafo)	100%	—	100%
Ponte híbrida (vão semântico + arestas)	100%	6,67%	0%
Retração dependente (AGM)	100%	—	—

Table 7: Ablação com baselines de produção. O conflito temporal é totalmente explicado apenas pelos metadados de timestamp (Config D vs. A: +70 pp, $p = 5,39 \times 10^{-27}$); o multi-hop é totalmente explicado pela estrutura de grafo (SQLite CTE e Álgebra ambos 100%). Apenas a ponte semântico-relacional híbrida favorece unicamente a álgebra (Álgebra 100%, SQLite 0%, VectorDB 6,67%; $p = 7,46 \times 10^{-14}$ vs. SQLite, $p < 10^{-13}$ vs. VectorDB).

Três achados delimitam a contribuição empírica da álgebra:

- **Conflito temporal:** os metadados de timestamp sozinhos respondem por 100% do ganho—não há vantagem de grafo.
- **Multi-hop:** a estrutura de grafo sozinha responde por 100% do ganho—o CTE do SQLite iguala a álgebra.
- **Ponte híbrida (vão semântico + arestas):** apenas a álgebra atinge 100%, enquanto o SQLite alcança 0% e o VectorDB 6,67%. Para a retração dependente sob os postulados AGM, a retração local da álgebra coincide com a mutilação mínima AGM (100%).

A vantagem empírica da álgebra reside, portanto, especificamente na *travessia híbrida semântico-relacional*, e não em tarefas solucionáveis apenas por metadados ou estrutura de grafo.

5.7 Validação de QA Multi-hop

A álgebra recupera corretamente o caminho transitivo $A \rightarrow B \rightarrow C \rightarrow D$ sem que a aresta direta $A \rightarrow D$ tenha sido inserida, confirmando que a semântica relacional sobrevive à composição.

5.8 Fase 4: Validação com Embeddings Reais

As fases anteriores utilizam embeddings sintéticos com estrutura de correlação controlada. A Fase 4 valida a álgebra com embeddings reais de linguagem natural gerados pelo modelo **all-MiniLM-L6-v2** (sentence-transformers, 384 dimensões, normalização L2) sobre 20 pares de fato/paráfrase cobrindo domínios diversos. O limiar de fusão é $\theta = 0,60$, adequado à distribuição de similaridade do modelo.

A associatividade é estrutural: preserva-se fora do regime ortogonal sintéticos. A recuperação por paráfrase atinge 100% top-1, demonstrando que a fusão por similaridade opera corretamente sobre a distribuição real de embeddings, onde conceitos semanticamente próximos apresentam alta correlação.

A Fase 4 também foi avaliada em escala preliminar: com $N = 10,000$ memórias ($\theta = 0,85$), a composição em lote leva 0,007 s e a recuperação leva ~ 20 s, retornando 9.990 nós. É fundamental

Critério	Resultado	Status
Associatividade exata	<code>assoc_exact=true</code> , invariante à ordem	APROVADO
Recuperação semântica (paráfrase $\rightarrow$ fato)	top-1 = 100% (20/20), score médio 0,895	APROVADO
Estabilidade sob composição sequencial	primeira memória recuperada (20 nós)	APROVADO
Multi-hop com arestas relacionais	opera corretamente em hops = 2	APROVADO

Table 8: Validação com embeddings reais (all-MiniLM-L6-v2). Dados em `experiments/results_phase4.json`.

documentar com honestidade a natureza patológica deste resultado: o corpus sintético de escala foi gerado por um **template único compartilhado** (“Fact number i about topic $i \bmod 50$: the value is X and the category is $i \bmod 50$ ”), no qual 90% dos tokens são idênticos em todas as sentenças. Como demonstrado empiricamente na Seção 6.2, este corpus não reflete a distribuição típica de linguagem natural diversa, mas sim um conjunto de quase-duplicatas: 99,8% dos pares possuem similaridade de cosseno $\geq 0,70$ e 53,0% possuem $\geq 0,85$ ($\mu = 0,852, \sigma = 0,042$). A $\theta = 0,85$, o grau médio de cada nó atinge $\langle k \rangle \approx 5.299 \gg 1$, empurrando o quociente single-linkage profundamente para o regime supercrítico de percolação e colapsando 99,9% do grafo em um componente gigante monolítico. O tempo de recuperação de ~ 20 s reflete a travessia exaustiva desses 9.990 nós artificialmente conectados. Esta execução, portanto, constitui um teste de estresse de colapso por percolação sob quase-duplicatas, e não uma validação de larga escala em texto livre heterogêneo. A escalabilidade viável requer operar estritamente no regime subcrítico ($\langle k \rangle < 1$), analisado teórica e empiricamente na Seção 6.2. Este resultado patológico é um artefato do corpus gerado por template único compartilhado, e não um comportamento típico: em corpora diversos com vão espectral (distribuição de similaridade bimodal), $\theta = 0,85$ preserva a estrutura dos componentes e o maior componente permanece limitado ao tamanho do cluster (Tabela 13).

5.9 Fase 5: Integração com LLM

A Fase 5 valida a álgebra como camada de memória para um agente LLM real (`stepfun/step-3.7-flash:free` via Kilo Gateway, sem API key). O agente consulta `retrieve()` como ferramenta e `compose()` para armazenar fatos.

Cenário	Álgebra	LLM (com memória)	Status
Conflito temporal	fato correto recuperado	“engineer”	PASS
Retração	fato retraído ausente	“Paris”	PASS
Multi-hop	3 nós recuperados	—	PASS

Table 9: Integração LLM (Fase 5). Dados em `experiments/results_phase5.json`.

Em escala (Fase 5 Scale), a álgebra foi testada como camada de memória com $N = 50$ a 500 fatos reais:

A álgebra funciona como camada de memória para LLM real: em $N = 500$, todas as métricas atingem 100%. A composição permanece $O(N)$ e o retrieve escala linearmente (~ 1 ms por fato adicional).

5.10 Fase 5C: Agente ReAct Multi-Modelo

Para verificar se o ganho de acurácia independe do modelo LLM, implementamos um agente ReAct (Thought $\rightarrow$ Action $\rightarrow$ Observation) que consulta a álgebra via ferramentas `memory_search(query,`

N	Retrieval	Temporal	Retração	Compose (s)	Retrieve (s)
50	80%	60%	100%	0,00	0,01
100	80%	100%	100%	0,00	0,01
200	90%	100%	100%	0,00	0,02
500	100%	100%	100%	0,01	0,46

Table 10: Fase 5 Scale: álgebra como camada de memória LLM em escala. Dados em `experiments/results_phase5_scale.json`.

`k`, `hops`) e `get_node(name)`, e o comparamos com um baseline sem memória em 4 cenários (recuperação de fato privado, conflito temporal, retração e multi-hop):

Modelo	ReAct	Baseline	Ferramentas/cenário
<code>dots-studio/dots-3-note-preview:free</code>	100%	25%	1,75
<code>inclusionai/ling-3.0-flash-vl:free</code>	100%	25%	3,00
<code>nex-agi/nex-n2.5-pro:free</code>	50%	25%	0,50
<code>stepfun/step-3.7-flash:free</code>	50%	25%	1,00

Table 11: Fase 5C: agente ReAct com álgebra de memória vs. baseline sem memória em 4 modelos. Dados em `experiments/results_phase5_react_models.json`.

Em todos os modelos disponíveis, o agente ReAct supera o baseline. Em 2 dos 4 modelos, a álgebra eleva a acurácia de 25% para 100%, confirmando que a melhoria é atribuível à camada de memória algébrica e não ao modelo LLM. Dois modelos adicionais (`nvidia/nemotron-3-ultra-550b-a55b:free` e `poolside/laguna-s-2.1:free`) retornaram HTTP 404 (indisponíveis no gateway gratuito) e foram excluídos.

6 Discussão

6.1 Principais Descobertas

1. **Associatividade exata é alcançável** através de computação diferida do quociente. O insight algébrico—de que a composição deve ser uma operação sem perda (união disjunta) com fusão semântica derivada sob demanda—resolve a tensão fundamental entre dependência da ordem de fusão e preservação estrutural.
2. **A estrutura protege contra agregação paramétrica.** Os componentes (G, T, P) blindam vetores individuais da diluição em relação à soma e à LSTM não-treinada. Um buffer kNN também preserva a estabilidade bruta, mas não possui ordenação temporal, retração ou travessia relacional.
3. **A diferenciação requer tarefas estruturais.** Em métricas de estabilidade pura, um buffer kNN simples tem desempenho comparável. A contribuição da álgebra emerge apenas quando ordenação temporal, retração ou travessia relacional são necessárias—precisamente as capacidades que distinguem memória estruturada de busca plana.

6.2 Análise de Encadeamento e Teoria de Percolação

O fecho transitivo single-linkage do operador de quociente pode encadear nós semanticamente distintos em um único componente gigante quando o limiar θ é selecionado abaixo do limiar crítico da distribuição de embeddings. Formalmente, o grafo quociente induzido por similaridade

sobre N memórias constitui um grafo aleatório geométrico no qual uma aresta não-direcionada existe entre u e v se e somente se $\cos(u, v) \geq \theta$. A probabilidade de aresta é dada por:

$$p(\theta) = \mathbb{P}(\cos(u, v) \geq \theta) = 1 - F_{\text{sim}}(\theta),$$

onde F_{sim} é a função de distribuição acumulada (CDF) empírica das similaridades par a par. O grau médio esperado dos nós é:

$$\langle k \rangle = p(\theta) \cdot (N - 1).$$

Pela teoria clássica de percolação em grafos aleatórios (Erdős–Rényi e grafos geométricos na esfera [21]), a transição de fase para a emergência de um componente gigante (que engloba uma fração finita $S > 0$ do grafo) ocorre precisamente quando o grau médio supera o limiar unitário:

$$\langle k \rangle > 1 \iff p(\theta_{\text{crit}}) = \frac{1}{N - 1}.$$

Por que θ_{crit} Não é Invariante em N em Distribuições Genéricas: Em uma distribuição contínua unimodal sem descontinuidades espectrais, $F_{\text{sim}}(\theta)$ é estritamente crescente. À medida que o acervo N cresce, a quantidade $1/(N - 1)$ encolhe assintoticamente em direção a zero (0,0050 em $N = 200$; 0,0010 em $N = 1.000$; 0,0002 em $N = 5.000$; 0,0001 em $N = 10.000$). Consequentemente, para satisfazer $p(\theta_{\text{crit}}) = 1/(N - 1)$, o limiar crítico é forçado a avançar para a cauda superior da distribuição:

$$\theta_{\text{crit}}(N) = F_{\text{sim}}^{-1}\left(1 - \frac{1}{N - 1}\right),$$

o que implica que $\theta_{\text{crit}}(N)$ **cresce estritamente com N** . A alegação de que θ_{crit} seria constante em N é, portanto, teoricamente incorreta como enunciado geral.

Distribuição Empírica e o Vão Espectral em Corpora Clustered: Para investigar experimentalmente por que corpora estruturados aparentam exibir estabilidade do limiar crítico, conduzimos um experimento sistemático computando as distribuições empíricas completas de similaridades par a par ($\sim 5 \times 10^7$ pares por corpus em $N = 10.000$) sobre três corpora distintos gerados com all-MiniLM-L6-v2 (Tabela 12):

- (a) **Corpus Clustered (20 tópicos):** 20 tópicos semânticos disjuntos com variações parafrásticas por tópico.
- (b) **Corpus Heterogêneo:** sentenças combinatórias abertas sem agrupamento em clusters, gerando suporte contínuo e unimodal.
- (c) **Corpus Sintético Patológico (Fase 4 Scale):** o corpus de escala preliminar gerado por template repetitivo compartilhado (“Fact number i about topic $i \bmod 50 \dots$ ”).

A decomposição do Corpus Clustered na Tabela 12 desvenda o mecanismo físico:

- Entre pares intra-tópico e inter-tópico existe um **vão espectral** pronunciado em $[0,50, 0,70]$, onde a densidade de probabilidade é virtualmente nula (0,255% dos pares).
- Como os pares intra-tópico representam apenas $1/K = 1/20 = 5\%$ de todos os pares do grafo, para qualquer $\theta \in [0,60, 0,85]$ as arestas formam-se *estritamente dentro* de cada um dos 20 clusters disjuntos de tamanho $N/20$.
- Portanto, a fração do maior componente é rigidamente limitada em $1/K = 0,0500$ ao longo de todo esse intervalo, para todos os $N \in [200, 10.000]$ (Tabela 13).

Corpus ($N = 10.000$)	Pares	μ	σ	Mediana	P_{90}	P_{99}	Vão $[0,5; 0,7]$
(a) Clustered (20 tópicos)	49.995.000	0,107	0,190	0,060	0,221	0,891	0,25%
$\hookrightarrow$ Intra-tópico (5%)	2.497.500	0,838	0,076	0,843	0,933	0,976	3,69%
$\hookrightarrow$ Inter-tópico (95%)	47.497.500	0,068	0,086	0,059	0,181	0,296	0,07%
(b) Heterogêneo	49.995.000	0,242	0,120	0,231	0,398	0,589	2,84%
(c) Patológico (Template)	49.995.000	0,852	0,042	0,852	0,902	0,948	0,21%

Table 12: Distribuição empírica de similaridades par a par de cosseno em $N = 10.000$. O Corpus Clustered revela bimodalidade nítida com pico intra-tópico ($\mu = 0,838$), pico inter-tópico ($\mu = 0,068$) e vão espectral profundo em $[0,50, 0,70]$ (0,25% dos pares). O Corpus Heterogêneo exibe suporte contínuo unimodal. O Corpus Patológico concentra 99,8% dos pares em $\cos \geq 0,70$. Dados em `experiments/results_percolation_histogram.json`.

- O componente gigante global (fração $> 0,50$) somente se manifesta quando θ desce para a distribuição inter-tópico ($\theta \leq 0,35$), ponto em que arestas entre tópicos fundem os clusters.
- Por conseguinte, o ponto de transição global fica *ancorado* no limite do vão inter-tópico. Esta estabilidade aparente é uma propriedade particular de corpora com 20 clusters bem separados, e não uma invariância geral do método.

N	$1/(N-1)$	Corpus Heterogêneo (b)			Corpus Clustered (a)		
		$\theta_{\text{crit}}^{\text{emp}}$	$\theta_{\text{crit}}^{\text{teor}}$	Gigante(0,85)	$\theta_{\text{crit}}^{\text{emp}}$	Gigante(0,60)	Gigante(0,85)
200	0,00502	0,57	0,616	0,005	0,30	0,050	0,050
1.000	0,00100	0,67	0,697	0,002	0,30	0,050	0,050
5.000	0,00020	0,73	0,762	0,001	0,34	0,050	0,050
10.000	0,00010	0,76	0,786	0,001	0,35	0,050	0,050

Table 13: Transição de percolação em função de N . No Corpus Heterogêneo, θ_{crit} cresce estritamente com N ($0,57 \rightarrow 0,76$), acompanhando a previsão teórica $\theta_{\text{crit}}^{\text{teor}} = F_{\text{sim}}^{-1}(1 - 1/(N-1))$. No Corpus Clustered, o componente gigante global fica ancorado no limiar inter-tópico ($\sim 0,30-0,35$), enquanto no vão espectral ($\theta \in [0,60, 0,85]$) o maior componente é exatamente limitado ao tamanho do cluster ($1/K = 0,050$). Dados em `experiments/results_percolation_histogram.json`.

Falha da Heurística $\mu + 2\sigma$ e a Regra Acionável por Quantil: A heurística adaptativa $\theta_{\text{adapt}} = \mu + 2\sigma$ falha categoricamente em prevenir o colapso por ser invariante em N :

- No Corpus Heterogêneo, $\theta_{\text{adapt}} \approx 0,48$ induz um grau médio $\langle k \rangle = 372,0$ em $N = 10.000$, colapsando 100% dos nós em um componente gigante.
- No Corpus Patológico, $\theta_{\text{adapt}} \approx 0,936$ induz $\langle k \rangle = 184,3$ em $N = 10.000$, colapsando 96,1% dos nós.

A regra operacional rigorosa e matematicamente garantida decorrente da condição de subcriticidade $\langle k \rangle < 1$ é calibrar o limiar como o **quantil empírico de ordem $1 - c/N$** :

$$\theta(N) = Q_{1-c/N}(\text{sim}), \quad \text{com } c < 1 \text{ (por exemplo, } c = 0,8\text{).} \quad (1)$$

Demonstração: Pela definição de quantil empírico sobre o conjunto de pares, a proporção de pares com similaridade $\geq \theta(N)$ satisfaz $p(\theta(N)) \leq c/N$. Portanto:

$$\langle k \rangle = p(\theta(N)) \cdot (N-1) \leq \frac{c}{N} \cdot (N-1) = c \left(1 - \frac{1}{N}\right) < c < 1.$$

O grafo de fusão é garantido estar estritamente no regime subcrítico de percolação. Por teoremas clássicos de componentes conexos subcríticos, o maior componente é limitado em $O(\log N)$, e sua fração $|C_{\max}|/N \rightarrow 0$ quando $N \rightarrow \infty$.

A Tabela 14 valida a eficácia universal desta regra: em todos os valores de N e em todos os três corpora, $\theta(N) = Q_{1-0,8/N}$ garante exatamente $\langle k \rangle = 0,800$, impedindo a formação de componente gigante (fração $\leq 0,051$ no heterogêneo, $\leq 0,025$ no clustered e $\leq 0,125$ no patológico). Praticantes podem estimar $Q_{1-c/N}$ em tempo prático amostrando uma matriz esparsa de similaridades ($M \ll N^2$) ou calibrando em um lote de referência.

Corpus	N	Regra do Quantil ($c = 0,8$)		Heurística $\mu + 2\sigma$		Limiar Fixo $\theta = 0,85$	
		$\theta(N)$	Gigante	θ_{adapt}	Gigante	$\langle k \rangle$	Gigante
(b) Heterogêneo	200	0,631	0,045	0,492	0,990	0,00	0,005
	1.000	0,709	0,051	0,483	1,000	0,01	0,002
	5.000	0,770	0,050	0,483	1,000	0,08	0,001
	10.000	0,794	0,045	0,482	1,000	0,14	0,001
(c) Patológico	200	0,951	0,125	0,934	0,560	113,8	1,000
	1.000	0,969	0,036	0,933	0,908	541,4	1,000
	5.000	0,977	0,090	0,934	0,926	2.470,8	1,000
	10.000	0,982	0,014	0,936	0,961	5.298,6	1,000

Table 14: Validação comparativa da Regra Operacional do Quantil $\theta(N) = Q_{1-0,8/N}$ vs. heurística adaptativa e limiar fixo $\theta = 0,85$. A regra do quantil garante $\langle k \rangle = 0,800 < 1$ e previne confiavelmente o componente gigante em todos os cenários. Dados em `experiments/results_percolation_histogram.json`.

6.3 Limitações

1. **Escala:** LSH encadeado e composição em lote permitem $N = 10^4$ memórias em 4 GB de RAM (retrieve 0,478s). Escalar além de 10^4 requer arquiteturas de armazenamento esparsas ou streaming.
2. **Escala e Diversidade do Corpus:** A Fase 4 valida a recuperação semântica com 20 pares de fatos reais com paráfrases naturais (100% top-1 na recuperação de paráfrases), enquanto o teste preliminar de escala a $N = 10^4$ na Fase 4 utilizou sentenças sintéticas com template compartilhado, resultando em quase-duplicatas e colapso por percolação. A Seção 6.2 valida rigorosamente a dinâmica de percolação até $N = 10^4$ com embeddings reais sob corpora multi-tópico e heterogêneos, estabelecendo as condições de subcriticidade. Validação empírica em corpora conversacionais massivos e não-curados com diálogo humano ruidoso e vocabulário aberto permanece trabalho futuro.
3. **Cenário Single-Agent:** A álgebra é validada para composição de memória de um único agente. Memória compartilhada multi-agente introduz desafios adicionais de consistência, concorrência e quociente distribuído.
4. **Seleção Operacional do Limiar e Dependência de N :** Conforme provado na Seção 6.2, o limiar crítico $\theta_{\text{crit}}(N)$ é inerentemente dependente de N em corpora gerais. Para prevenir o encadeamento descontrolado (chaining) em qualquer acervo, praticantes não devem utilizar regras fixas de desvio-padrão ($\mu + 2\sigma$), mas sim a regra do quantil empírico $\theta(N) = Q_{1-c/N}(\text{sim})$ com $c < 1$ (e.g., $c = 0,8$), que garante matematicamente o regime subcrítico $\langle k \rangle \leq c < 1$.

6.4 Relação com Trabalhos Anteriores

Posicionamos a álgebra da memória em relação a quatro paradigmas fundamentais na representação de conhecimento, inteligência artificial e arquiteturas de memória:

6.4.1 Revisão de Crenças e o Framework AGM

A dinâmica de crenças na IA simbólica foi formalizada por Alchourrón, Gärdenfors e Makinson (AGM) [3], definindo três operações canônicas sobre conjuntos de crenças: expansão ($K + \phi$), contração ($K \div \phi$) e revisão ($K * \phi$). Em nossa álgebra da memória, o operador de retração $\ominus$ fornece uma realização operacional da contração de crenças sobre estruturas relacionais atribuídas em **Mem**.

O operador de retração satisfaz os postulados centrais de contração de AGM:

1. *Fechamento (Closure)*: $M \ominus m_i \in \mathbf{Mem}$ é um objeto de memória válido e bem-formado.
2. *Inclusão (Inclusion)*: $N(M \ominus m_i) \subseteq N(M)$ e $E(M \ominus m_i) \subseteq E(M)$.
3. *Vacuidade (Vacuity)*: Se m_i não possui nós em M , então $M \ominus m_i = M$.
4. *Sucesso (Success)*: Os nós e arestas incidentes de m_i são rigorosamente eliminados da representação ativa.

O Postulado de Recuperação e Contração em Cascata: O quinto postulado AGM—Recuperação (Recovery: $K \subseteq (K \div \phi) + \phi$)—afirma que se uma crença é contraída e posteriormente reintroduzida, nenhuma crença original é perdida. A Recuperação é historicamente reconhecida como o postulado mais controverso e problemático da teoria AGM [4, 5]. Em memórias estruturadas em grafos, esse debate manifesta-se concretamente: quando um nó atômico u é retraído ($M \ominus \{u\}$), todas as arestas relacionais incidentes (u, v) e (w, u) devem ser seccionadas para preservar o fechamento e a integridade estrutural do grafo. Se u for posteriormente recomposto ($M \oplus \{u\}$), as arestas seccionadas não são automaticamente restabelecidas a menos que uma proveniência de dependências tenha sido preservada explicitamente. Portanto, na álgebra da memória, a Recuperação vale estritamente para *subvistas isoladas* (conforme formalizado em nossa lei de lentes Get-Put, Seção 3), mas falha naturalmente em redes interconectadas onde arestas incidentes foram cortadas—espelhando diretamente o dilema fundacional de recuperação da teoria AGM.

6.4.2 Sistemas de Manutenção da Verdade (TMS)

O raciocínio não-monotônico na IA simbólica conduziu aos Sistemas de Manutenção da Verdade, notadamente o TMS baseado em justificativas de Doyle (JTMS) [6] e o TMS baseado em suposições de de Kleer (ATMS) [7]. Um TMS registra explicitamente dependências entre premissas, justificativas e inferências derivadas para executar backtracking direcionado por dependências quando contradições são encontradas.

Sistemas conexionistas e bancos vetoriais são fundamentalmente incapazes de manutenção da verdade: porque a informação está distribuída em pesos densos ou listas planas de vetores, retrain uma premissa não propaga para suas inferências dependentes sem corromper ou reindexar cegamente o espaço vetorial. Em contraste, o componente de grafo atribuído G em (V, G, T, P) fornece arestas relacionais explícitas que funcionam como elos de justificativa. Quando uma premissa antecedente é removida via $\ominus$, a travessia de grafo permite identificar e executar retrações em cascata sobre as inferências a jusante, unindo conceitos clássicos de TMS a espaços vetoriais contínuos.

6.4.3 Grafos de Conhecimento Temporais (TKGs)

A modelagem de fatos relacionais dinâmicos no tempo foi extensamente investigada em Grafos de Conhecimento Temporais, incluindo modelos de projeção em hiperplanos como HyTE [8], embeddings temporais baseados em translação como TTransE [9], e processos pontuais contínuos como Know-Evolve [10]. Esses modelos associam intervalos temporais $[t_s, t_e]$ ou timestamps contínuos a quadruplas $(s, r, o, [t_s, t_e])$.

A álgebra da memória integra esse princípio em uma estrutura categórica unificada: cada nó atômico carrega um timestamp contínuo $\tau \in T = (\mathbb{R}_{\geq 0}, \leq)$. Em vez de projetar entidades estaticamente em hiperplanos rígidos ou sobrescrever fatos passados destrutivamente, nosso operador de recuperação ρ emprega um kernel de decaimento/ancoragem temporal $f_T(c) = \exp(-((t_c - t_q)/\sigma)^2)$. Isso permite que o objeto de memória preserve trajetórias temporais completas, capacitando o agente a consultar a base a partir de qualquer perspectiva temporal t_q e resolver atualizações sob demanda.

6.4.4 Arquiteturas Modernas de Memória de Agentes e GraphRAG

Recentes avanços em agentes baseados em LLMs impulsionaram arquiteturas práticas de memória: MemGPT [17] implementa paginação hierárquica estilo sistema operacional entre prompt, memória de trabalho e armazenamento em disco; Generative Agents [18] utilizam árvores de reflexão e pontuação recência-importância; GraphRAG [11] constrói grafos de comunidades hierárquicas (via clustering de Leiden) e sumarizações pré-computadas; e sistemas conversacionais como Zep/Graphiti mantêm grafos de conhecimento temporais para diálogo.

Embora empiricamente eficazes, esses sistemas dependem de loops heurísticos de prompts de LLM, repositórios ad-hoc em JSON ou consultas pontuais a bancos vetoriais. Eles carecem de garantias algébricas formais: a ordem de composição importa, retrações são heurísticas e atualizações bidirecionais não possuem leis de consistência. A álgebra da memória fornece o substrato algébrico formal que falta a esses sistemas: a associatividade provada garante que memórias possam ser compostas em paralelo entre múltiplos subagentes; o quociente coequalizador fornece uma base matemática para a fusão de entidades; e as leis de lentes get/put garantem sincronização bidirecional previsível entre vistas de agentes e a memória persistente.

6.4.5 Outros Modelos Conexionistas e Paramétricos

Nossa abordagem também se relaciona, mas difere, de:

- **Redes de memória composicional** [12]: Utilizam slots de memória de tamanho fixo com endereçamento por atenção, sem associatividade e retração exata.
- **Completação de grafos de conhecimento** [13]: Modela relações estáticas mas carece de uma álgebra composicional com associatividade provável.
- **Computadores Neurais Diferenciáveis** [14]: Fornecem endereçamento por conteúdo mas sofrem da mesma dinâmica de interferência que RNNs sob escrita sequencial.
- **Transformações bidirecionais baseadas em lentes** [15]: Estendemos lentes clássicas em árvores para grafos relacionais atribuídos com métricas temporais e de utilidade.
- **Regularizadores de aprendizado contínuo** [16]: Métodos como EWC mitigam esquecimento no espaço de parâmetros, mas não expõem retração exata ou composição associativa.
- **Recurrent Memory Transformer** [19]: Adiciona tokens de memória explícitos a transformers; permanece um modelo paramétrico sem composição estilo pushout.

- **Redes de Hopfield modernas** [20]: Fornecem garantias de recuperação associativa, mas carecem de resolução de conflitos temporais, retração ou composição relacional multi-hop.

7 Conclusão

A álgebra da memória (V, G, T, P) fornece composição associativa exata ao tratar a composição como operação estrutural sem perda (coproduto / união disjunta em **Mem**) e derivar a fusão semântica sob demanda via quociente categórico (coequalizador) de uma relação de similaridade. Essa propriedade é uma decisão arquitetural de design explícita, verificada empiricamente em 50 seeds, todas as configurações de parâmetros testadas e entradas adversariais.

A álgebra não supera todas as baselines em estabilidade vetorial bruta: LSTM treinada em amostra e kNN atingem distância final menor no protocolo isolado de estabilidade. Sua contribuição, portanto, não é dominância universal de estabilidade, mas um objeto de memória estruturalmente mais rico. Em tarefas que exigem ordenação temporal, retração ou travessia relacional, a álgebra atinge 100% de acerto, enquanto o kNN alcança 50%, 33–43% e 87–93%, respectivamente.

A validação com embeddings reais de linguagem natural (Fase 4) confirma que associatividade, recuperabilidade e estabilidade se mantêm fora do regime sintético: 100% de precisão top-1 em recuperação por paráfrase (20/20, score médio 0,895). Escalabilidade para $N = 10^4$ memórias em 4 GB de RAM é alcançada via LSH encadeado e composição em lote (retrieve 0,478 s); escalar além de 10^4 requer otimizações de armazenamento esparsos. Ao estabelecer elos rigorosos com contração de crenças AGM, Sistemas de Manutenção da Verdade e Grafos de Conhecimento Temporais, este trabalho fornece uma base algébrica principled para memória persistente e composicional em agentes de IA.

Disponibilidade de Dados e Código

Todos os dados experimentais, scripts de análise e código de implementação estão disponíveis no repositório do projeto em <https://github.com/pedrofariasx/memory-algebra> (DOI Zenodo: 10.5281/zenodo.22815162). Resultados brutos são fornecidos em formato JSON (`experiments/results_phase2.json`, `experiments/results_phase3.json`, `experiments/results_phase4.json`, `experiments/results_phase5.json`, `experiments/results_chaining_curve.json`).

References

- [1] McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. *The Psychology of Learning and Motivation*, 24, 109–165.
- [2] French, R. M. (1999). Catastrophic forgetting in connectionist networks. *Trends in Cognitive Sciences*, 3(4), 128–135.
- [3] Alchourrón, C. E., Gärdenfors, P., & Makinson, D. (1985). On the logic of theory change: Partial meet contraction and revision functions. *The Journal of Symbolic Logic*, 50(2), 510–530.
- [4] Makinson, D. (1987). On the status of the postulate of recovery in the logic of theory change. *Journal of Philosophical Logic*, 16(4), 383–394.
- [5] Hansson, S. O. (1999). *A Textbook of Belief Dynamics: Theory Change and Database Updating*. Springer Science & Business Media, Dordrecht.
- [6] Doyle, J. (1979). A truth maintenance system. *Artificial Intelligence*, 12(3), 231–272.

- [7] de Kleer, J. (1986). An assumption-based TMS. *Artificial Intelligence*, 28(2), 127–162.
- [8] Dasgupta, S. S., Ray, S. N., & Talukdar, P. (2018). HyTE: Hyperplane-based temporally-aware knowledge graph embedding. *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2001–2011.
- [9] Leblay, J., & Chekol, M. W. (2018). Deriving valid relation constraints from temporal knowledge graph embeddings. *Proceedings of the 2018 World Wide Web Conference (WWW)*, 1793–1802.
- [10] Trivedi, R., Dai, H., Wang, Y., & Song, L. (2017). Know-Evolve: Deep temporal reasoning for dynamic knowledge graphs. *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 3462–3471.
- [11] Edge, D., Trinh, H., Cheng, N., et al. (2024). From local to global: A graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*.
- [12] Sukhbaatar, S., Weston, J., & Fergus, R. (2016). End-to-end memory networks. *Advances in Neural Information Processing Systems*, 28.
- [13] Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). Translating embeddings for modeling multi-relational data. *Advances in Neural Information Processing Systems*, 26.
- [14] Graves, A., Wayne, G., Reynolds, M., et al. (2016). Hybrid computing using a neural network with dynamic external memory. *Nature*, 538(7626), 471–476.
- [15] Foster, J. N., Greenwald, M. B., Moore, J. T., Pierce, B. C., & Schmitt, A. (2007). Combinators for bidirectional tree transformations: A linguistic approach to the view-update problem. *ACM Transactions on Programming Languages and Systems*, 29(3), 17.
- [16] Kirkpatrick, J., Pascanu, R., Rabinowitz, N., et al. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521–3526.
- [17] Packer, C., Wooders, S., Lin, K., et al. (2023). MemGPT: Towards LLMs as operating systems. *arXiv preprint arXiv:2310.08560*.
- [18] Park, J. S., O’Brien, J. C., Cai, C. J., et al. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, Article 2.
- [19] Bulatov, A., Kuratov, Y., & Burtsev, M. (2022). Recurrent memory transformer. *arXiv preprint arXiv:2207.06881*.
- [20] Ramsauer, H., Schäfl, B., Lehner, J., et al. (2021). Hopfield networks is all you need. *International Conference on Learning Representations*.
- [21] Penrose, M. D. (2003). *Random Geometric Graphs*. Oxford University Press.

A Detalhes de Implementação

A álgebra da memória é implementada em Python (pacote `memory_algebra`) com os seguintes módulos:

- `core.py`: `MemoryObject`, `compose`, `quotient`, `retrieve`, `retract`, `transform`

- `diff.py`: Álgebra diferenciável (JAX) com amostragem de arestas Gumbel-Softmax
- `metric.py`: Distância semântica híbrida d_s com pesos adaptativos ao contexto
- `lens.py`: Operações de lente get/put
- `stability.py`: Operador de poda Π_C
- `baselines.py`: Implementação da baseline LSTM

A validação de ground truth categórico utiliza Catlab.jl 0.15 (Julia) com verificações `is_isomorphic` em diagramas de pushout.

B Métodos Estatísticos

- Todos os experimentos utilizam seeds aleatórias independentes (50 para Fase 2A, 30 para Fase 3).
- Significância estatística: teste Mann–Whitney U unilateral (não-paramétrico, amostras independentes), testando se a álgebra tem distância final menor.
- Intervalos de confiança: Bootstrap (95%).
- Tamanhos de efeito reportados como diferenças brutas nas taxas de sucesso.