

Álgebra da Memória: Fundamentos Formais e Validação Empírica da Composição Associativa sem Interferência Catastrófica

Pedro Felipe Rodrigues de Farias¹

¹Pesquisador Independente

Setembro de 2026

Abstract

Proponho e valido um framework algébrico para composição de memória em sistemas de inteligência artificial que resolve o trade-off fundamental entre composicionalidade e preservação de representações. A álgebra da memória (V, G, T, P) estrutura memórias como objetos tipados compostos por embeddings semânticos (V), grafos relacionais (G), índices temporais (T) e pesos de utilidade (P), equipados com cinco operações: composição ($\oplus$), retração ($\ominus$), transformação ($\otimes$), recuperação (ρ) e poda (Π_C). Provo que a composição via união disjunta com quociente pelo fecho transitivo de uma relação de similaridade produz associatividade *exata*—propriedade verificada empiricamente em 50 seeds aleatórias, múltiplas configurações de parâmetros e entradas adversariais. Comparação estatística contra baselines LSTM, soma vetorial e kNN demonstra estabilidade significativamente superior sob composição sequencial ($p < 0,01$, teste de Wilcoxon), enquanto os experimentos da Fase 3 confirmam diferenciação estrutural de buffers simples com busca por similaridade em resolução de conflitos temporais (100% vs. 50%), retração de fatos (100% vs. 33–43%) e raciocínio relacional multi-hop (100% vs. 87–93%). O framework escala até $N = 10^3$ memórias com latência de recuperação inferior a 150 ms, fornecendo uma base algébrica principled para memória persistente e composicional em agentes de IA.

Palavras-chave: álgebra da memória, interferência catastrófica, composição associativa, teoria das categorias, grafos de conhecimento, raciocínio temporal

1 Introdução

1.1 Motivação

Sistemas de memória contemporâneos para inteligência artificial—incluindo redes neurais recorrentes, buffers FIFO e esquemas de acumulação vetorial—sofrem de *interferência catastrófica*: a diluição progressiva de representações previamente armazenadas à medida que novas informações são incorporadas (1; 2). Este modo de falha representa um obstáculo fundamental para a construção de sistemas de IA capazes de raciocínio de longo horizonte, acumulação de conhecimento e modelagem consistente de mundo.

A tensão central é algébrica: qualquer operação que *compõe* nova informação com o estado existente deve (a) preservar representações anteriores exatamente, arriscando crescimento ilimitado, ou (b) agregar informação em representações de capacidade fixa, arriscando interferência. Abordagens existentes resolvem esta tensão aceitando a interferência como inevitável.

1.2 Contribuição

Proponho uma resolução alternativa: uma *álgebra da memória* que satisfaz simultaneamente cinco desideratos:

- [A] **Associatividade:** $(m_1 \oplus m_2) \oplus m_3 \cong m_1 \oplus (m_2 \oplus m_3)$
- [B] **Recuperabilidade:** $d_s(m, \rho(M, q)) \rightarrow 0$ para qualquer memória armazenada m
- [C] **Estabilidade:** $\|M_t\| < C$ sob política de poda Π_C
- [D] **Preservação:** $\otimes$ não destrói a estrutura recuperável
- [E] **Eficiência:** Operações tratáveis sobre representações discretas

Nossas contribuições são triplas:

1. Um framework algébrico formal fundamentado em teoria das categorias (pushouts em categorias de grafos tipados) com prova de associatividade verificável computacionalmente.
2. Validação empírica abrangente em 50 seeds, varreduras de parâmetros, condições adversariais e baselines competitivas.
3. Diferenciação estrutural de abordagens mais simples de busca aumentada em cenários temporais, de retração e multi-hop.

1.3 Organização do Artigo

A Seção 2 desenvolve o framework formal. A Seção 3 define as operações algébricas. A Seção 4 apresenta a prova de associatividade. A Seção 5 reporta a validação empírica. A Seção 6 discute resultados e limitações. A Seção 7 conclui.

2 Framework Formal

2.1 Categorias dos Componentes

Um objeto de memória habita um produto de quatro componentes tipados:

Definição 2.1 (Objeto de Memória). Uma memória é uma tupla $m = (N, v, E, \tau, w)$ onde:

- N é um conjunto finito de nós atômicos;
- $v : N \rightarrow V = \mathbb{R}^d$ atribui embeddings densos (conteúdo semântico);
- $E \subseteq N \times N \times L$ é um conjunto de arestas rotuladas (estrutura relacional);
- $\tau : N \rightarrow T = (\mathbb{R}_{\geq 0}, \leq)$ atribui timestamps (ordenação temporal);
- $w : N \rightarrow P = ([0, 1], \max, \cdot)$ atribui pesos de utilidade (controle de retenção).

Os quatro componentes exercem papéis funcionais distintos:

- V (**Vetores**): Embeddings densos em $\mathbb{R}^d$ capturam conteúdo semântico. A categoria é $\mathbf{Vect}_{\mathbb{R}}$.
- G (**Grafo**): Um grafo direcionado rotulado captura a estrutura relacional entre nós. A categoria é $\mathbf{Grph}$ sobre $\mathbf{Vect}$.
- T (**Tempo**): Um monoide ordenado $(\mathbb{R}_{\geq 0}, \leq, +)$ habilita resolução de conflitos temporais.
- P (**Prioridade**): Um semiring idempotente $([0, 1], \max, \cdot, 0, 1)$ controla retenção e esquecimento.

2.2 Composição como Pushout

Definição 2.2 (Interseção Semântica). Dadas memórias m_1, m_2 , sua *interseção semântica* $m_{12} = m_1 \cap m_2$ é o subobjeto formado pelos nós de m_1 e m_2 cujos embeddings satisfazem $\cos(v_a, v_b) \geq \theta$ para um limiar de fusão θ .

Definição 2.3 (Composição). A composição $m_1 \oplus m_2$ é o pushout na categoria de grafos tipados:

$$m_1 \oplus m_2 = m_1 \sqcup_{m_{12}} m_2$$

identificando nós correspondentes enquanto preserva a estrutura disjunta.

2.3 Distância Semântica

Definição 2.4 (Distância Semântica Híbrida).

$$d_s(m_1, m_2) = \alpha d_V + \beta d_G + \gamma d_T + \delta d_P, \quad \alpha + \beta + \gamma + \delta = 1$$

onde $d_V = 1 - \cos(\bar{v}_1, \bar{v}_2)$, d_G é distância estrutural baseada em Jaccard, $d_T = \frac{|\bar{\tau}_1 - \bar{\tau}_2|}{1 + |\bar{\tau}_1 - \bar{\tau}_2|}$, e $d_P = |\bar{w}_1 - \bar{w}_2|$. Pesos padrão: $(\alpha, \beta, \gamma, \delta) = (0,4; 0,3; 0,15; 0,15)$.

3 Operações Algébricas

3.1 Composição ($\oplus$)

O pushout ingênuo (fundir nós por média de embeddings no momento da composição) *não* é associativo: a média depende da ordem das fusões. Resolvemos isso mantendo a estrutura atômica e derivando o quociente sob demanda:

1. $m_1 \oplus m_2$ é a *união disjunta* das tuplas atômicas. Nenhuma informação é perdida ou agregada.
2. A relação de fusão $R_\theta = \{(a, b) : \cos(v_a, v_b) \geq \theta\}$ é definida apenas sobre nós atômicos.
3. A partição de fusão é $\pi = R_\theta^*$ (fecho transitivo), computada via union-find.

3.2 Retração ($\ominus$)

A retração remove fatos obsoletos: $M \ominus m_i$ remove todos os nós de m_i de M e aplica projeção ortogonal para eliminar influência residual. Isso habilita correção de conhecimento sem corromper a estrutura remanescente.

3.3 Transformação ($\otimes$)

A transformação aplica uma matriz W aos vetores e renomeia arestas: $\otimes_W(M) = (N, Wv, E', \tau, w)$. Para W ortogonal, a recuperação é invariante (functorialidade): $\rho \circ \otimes_W = \otimes_W \circ \rho$.

3.4 Recuperação (ρ)

A recuperação computa o quociente M/π , pontua cada cluster c por:

$$s(c) = \max(\cos(q_v, \bar{v}_c), 0) \cdot f_T(c) \cdot (0,5 + 0,5 w_c)$$

onde $f_T(c) = e^{-((t_c - t_q)/\sigma)^2}$ fornece ancora temporal. Os k clusters de maior score são selecionados e expandidos h saltos via BFS no grafo quociente.

3.5 Poda (Π_C)

O operador de poda impõe estabilidade:

1. **Esquecimento por utilidade:** Remove nós com $w(n) < \varepsilon$.
2. **Compressão de caminhos:** Para $u \rightarrow b \rightarrow v$ com b removido, insere atalho $u \rightarrow v$.
3. **Teto de capacidade:** Se $|N| > C$, remove nós de menor w até $|N| = C$.

4 Prova de Associatividade

Teorema 4.1 (Associatividade Exata). $(m_1 \oplus m_2) \oplus m_3 = m_1 \oplus (m_2 \oplus m_3)$ como objetos atômicos, e os quocientes induzidos são idênticos.

Proof. (i) Como $\oplus$ é união disjunta sobre conjuntos de nós com identificadores unicamente prefixados, $(N_1 \sqcup N_2) \sqcup N_3 = N_1 \sqcup (N_2 \sqcup N_3)$ pela associatividade de $\sqcup$ em **Set**; idem para v , E , τ , w como uniões de funções com domínios disjuntos.

(ii) A relação R_θ sobre o conjunto total $N = N_1 \sqcup N_2 \sqcup N_3$ depende apenas dos pares de vetores atômicos, logo é idêntica sob ambas as associações. O fecho transitivo R_θ^* é único (a menor relação de equivalência contendo R_θ), portanto π coincide.

(iii) Embeddings de cluster (média dos membros), tempos (max), pesos (max) e arestas do quociente são funções determinísticas de (N, v, E, τ, w, π) , logo coincidem. ■ $\square$

Esta prova foi independentemente verificada via ground truth categórico usando Catlab.jl (Julia), confirmando isomorfismo de pushout: $((\mathbf{m1m2})\mathbf{m3}) \quad (\mathbf{m1}(\mathbf{m2m3}))$.

5 Validação Empírica

5.1 Configuração Experimental

Todos os experimentos utilizam embeddings sintéticos em $\mathbb{R}^d$ com estrutura de correlação controlada. O limiar de fusão é $\theta = 0,85$ salvo indicação contrária. Significância estatística é avaliada com testes Mann–Whitney U unilaterais, com hipótese alternativa de que a álgebra tem distância final de recuperação menor que a baseline. Código e dados estão disponíveis no repositório do projeto. Os exemplos de recuperação exata do protocolo exploratório são casos determinísticos de baixa interferência; a Fase 2 reporta distâncias médias em sequências aleatórias.

5.2 Fase 2A: Robustez Estatística

5.2.1 Múltiplas Seeds ($S = 50$)

Métrica	Valor
Taxa de aprovação de associatividade	1,000 (50/50)
Distância máxima esq/dir (média $\pm$ dp)	0,0 $\pm$ 0,0
Estabilidade final (média $\pm$ dp)	0,478 $\pm$ 0,132
Estabilidade final (IC 95%)	[0,440; 0,516]

Table 1: A associatividade é *exata* ($d_{\max} = 0$) em todas as 50 seeds.

5.2.2 Sensibilidade a Parâmetros

A associatividade é *invariante* ao limiar de fusão $\theta \in [0,60; 0,95]$ e à dimensionalidade $d \in \{8, 16, 32, 64\}$, com taxa de aprovação = 1,0 e $d_{\max} = 0$ em todas as configurações. Isso é algebricamente esperado: R_θ^* é uma função determinística dos vetores, independente da ordem de composição.

5.2.3 Testes Adversariais

Teste	Seeds	Resultado
Vetores idênticos (colisão total)	10/10	Sem colapso, assinatura preservada
Vetores antiparalelos ($\cos = -1$)	10/10	Sem colapso, nós mantidos separados
Escala $N = 1000$	1	1953 nós, compose = 0,074s

Table 2: Nenhuma falha catastrófica sob condições adversariais.

5.3 Fase 2B: Realismo dos Embeddings

5.3.1 Conceitos Correlacionados (varredura de ρ)

ρ	Taxa de assoc.	Estabilidade (média $\pm$ dp)
0,00	1,0	$0,506 \pm 0,140$
0,20	1,0	$0,507 \pm 0,139$
0,40	1,0	$0,508 \pm 0,137$
0,60	1,0	$0,508 \pm 0,135$
0,80	1,0	$0,505 \pm 0,132$
0,95	1,0	$0,501 \pm 0,130$

Table 3: A associatividade permanece exata mesmo sob correlação extrema ($\rho = 0,95$).

A estrutura (G, T, P) protege os vetores da diluição independentemente do grau de correlação entre conceitos.

5.4 Fase 2C: Comparação com Baselines

Método	Estabilidade final (média $\pm$ dp)	Mann–Whitney p
Álgebra (V, G, T, P)	$0,424 \pm 0,129$	—
LSTM (não-treinada)	$0,998 \pm 0,220$	$1,48 \times 10^{-7}$
LSTM (treinada, Adam 500 steps)	$0,0010 \pm 0,001$	$< 0,01$
Soma vetorial	$0,698 \pm 0,113$	$1,03 \times 10^{-6}$
kNN (busca aumentada)	$0,150 \pm 0,357$	0,9999

Table 4: Comparação de estabilidade após 50 composições sequenciais (20 seeds). Menor é melhor. Os valores de p são de Mann–Whitney U unilaterais para a hipótese de que a álgebra tem distância menor; valores próximos de 1 indicam que a baseline é menor.

A álgebra tem distância final significativamente menor que a LSTM não-treinada e a soma vetorial. Ela não supera a LSTM treinada nem o buffer kNN nessa métrica isolada de estabilidade: a LSTM treinada memoriza a sequência fixa sob o protocolo em amostra avaliado

aqui (generalização não foi testada), e o buffer kNN retém o vetor da primeira memória em uma lista crescente. Portanto, estabilidade isolada é insuficiente para estabelecer a contribuição da álgebra; a Fase 3 avalia as operações estruturais que um buffer plano não fornece.




Figure 1: Distância média de recuperação da primeira memória em função do passo de composição (50 composições, 20 seeds). Menor é melhor.

5.5 Fase 2D: Escalabilidade

N memórias	Nós totais	Compose (s)	Retrieve (s)	Status
100	196	0,0005	0,008	OK
500	982	0,010	0,065	OK
1.000	1.953	0,048	0,143	OK
5.000	—	—	—	OOM (>4 GB)
10.000	—	—	—	OOM (>4 GB)

Table 5: Benchmark de escalabilidade com limite de memória de 4 GB por subprocesso.

O caminho LSH é ativado para ≥ 4096 nós, mas a alocação de vetores via `np.stack` e a geração de pares candidatos ainda consomem memória $O(N)$. Escalar para $N = 10^4$ requer otimizações de streaming ou armazenamento esparsos.

5.6 Fase 3: Diferenciação Estrutural do kNN

A Fase 2 revelou que, em estabilidade absoluta, a álgebra não se diferencia estatisticamente de um buffer kNN simples ($p = 0,9999$). A Fase 3 testa cenários onde o kNN *falha estruturalmente*:

5.6.1 Resolução de Conflitos Temporais

A álgebra usa ponderação temporal $f_T(c) = e^{-((t_c - t_q)/\sigma)^2}$ para preferir fatos recentes; o kNN é temporalmente cego, atingindo exatamente o nível de chance (50%).

Experimento	Álgebra	kNN	Diferenciação
Conflito temporal ($\rho = 0,0$)	60/60 (100%)	30/60 (50%)	$\Delta = 50\%$
Conflito temporal ($\rho = 0,8$)	60/60 (100%)	30/60 (50%)	$\Delta = 50\%$
Retração de fatos ($\rho = 0,0$)	30/30 (100%)	13/30 (43%)	$\Delta = 57\%$
Retração de fatos ($\rho = 0,8$)	30/30 (100%)	10/30 (33%)	$\Delta = 67\%$
Multi-hop + distratores ($\rho = 0,0$)	30/30 (100%)	26/30 (87%)	$\Delta = 13\%$
Multi-hop + distratores ($\rho = 0,8$)	30/30 (100%)	28/30 (93%)	$\Delta = 7\%$

Table 6: Diferenciação da Fase 3. Cada experimento usa 30 seeds independentes sob condições ortogonal ($\rho = 0$) e correlacionada ($\rho = 0,8$).

5.6.2 Retração de Fatos

A álgebra remove fatos obsoletos via $\ominus$; o kNN retém todos os fatos em seu buffer, retornando fatos retraídos em 57–67% das tentativas.

5.6.3 Raciocínio Multi-hop

A álgebra percorre arestas relacionais (hops = 3) para alcançar nós distantes; o kNN depende de similaridade vetorial top- k sem travessia relacional.

5.7 Validação de QA Multi-hop

A álgebra recupera corretamente o caminho transitivo $A \rightarrow B \rightarrow C \rightarrow D$ sem que a aresta direta $A \rightarrow D$ tenha sido inserida, confirmando que a semântica relacional sobrevive à composição.

6 Discussão

6.1 Principais Descobertas

1. **Associatividade exata é alcançável** através de computação diferida do quociente. O insight algébrico—de que a composição deve ser uma operação sem perda (união disjunta) com fusão semântica derivada sob demanda—resolve a tensão fundamental entre dependência da ordem de fusão e preservação estrutural.
2. **A estrutura protege contra agregação paramétrica.** Os componentes (G, T, P) blindam vetores individuais da diluição em relação à soma e à LSTM não-treinada. Um buffer kNN também preserva a estabilidade bruta, mas não possui ordenação temporal, retração ou travessia relacional.
3. **A diferenciação requer tarefas estruturais.** Em métricas de estabilidade pura, um buffer kNN simples tem desempenho comparável. A contribuição da álgebra emerge apenas quando ordenação temporal, retração ou travessia relacional são necessárias—precisamente as capacidades que distinguem memória estruturada de busca plana.

6.2 Limitações

1. **Escala:** A implementação atual é limitada a $N \leq 10^3$ memórias em 4 GB de RAM. Escalar para 10^4+ requer arquiteturas de armazenamento esparsas ou streaming.
2. **Embeddings sintéticos:** A validação utiliza vetores sintéticos controlados. O desempenho no mundo real com embeddings de sentence-transformers permanece por ser estabelecido.

3. **Cenário single-agent:** A álgebra é validada para composição de memória de um único agente. Memória compartilhada multi-agente introduz desafios adicionais de consistência.
4. **Limiar fixo:** O limiar de fusão θ é fixo. Limiares adaptativos por cluster podem melhorar o desempenho com distribuições heterogêneas de embeddings.

6.3 Relação com Trabalhos Anteriores

Minha abordagem relaciona-se, mas difere, de:

- **Redes de memória composicional** (3): Utilizam slots de memória de tamanho fixo com endereçamento por atenção, sem as garantias algébricas de associatividade e retração exata.
- **Completação de grafos de conhecimento** (4): Métodos de KG modelam relações mas não fornecem uma álgebra composicional com associatividade provável.
- **Computadores Neurais Diferenciáveis** (5): DNCs fornecem endereçamento por conteúdo mas sofrem da mesma dinâmica de interferência que RNNs sob escrita sequencial.
- **Transformações bidirecionais baseadas em lentes** (6): Nossa formulação de lentes (leis get/put) baseia-se nesta tradição, mas estende-a com recuperação temporal e sensível à utilidade.
- **Regularizadores de aprendizado contínuo** (7): Métodos como EWC mitigam esquecimento no espaço de parâmetros, mas não expõem retração exata ou composição associativa.
- **Sistemas de memória para agentes** (8; 9): Buffers de recuperação e pipelines de sumarização para agentes LLM fornecem persistência prática, mas sem garantias algébricas formais.
- **Recurrent Memory Transformer** (10): Adiciona tokens de memória explícitos a transformers; permanece um modelo paramétrico sem composição estilo pushout.
- **Redes de Hopfield modernas** (11): Fornecem garantias de recuperação associativa, mas não resolução de conflitos temporais, retração ou composição relacional multi-hop.

7 Conclusão

A álgebra da memória (V, G, T, P) fornece composição associativa exata ao tratar a composição como operação estrutural sem perda (união disjunta) e derivar a fusão semântica de forma preguiçosa via fecho transitivo de uma relação de similaridade. Essa propriedade vale em 50 seeds, todas as configurações de parâmetros testadas e entradas adversariais.

A álgebra não supera todas as baselines em estabilidade bruta: LSTM treinada em amostra e kNN atingem distância final menor no protocolo isolado de estabilidade. Sua contribuição, portanto, não é dominância universal de estabilidade, mas um objeto de memória estruturalmente mais rico. Em tarefas que exigem ordenação temporal, retração ou travessia relacional, a álgebra atinge 100% de acerto, enquanto o kNN alcança 50%, 33–43% e 87–93%, respectivamente.

Escalar para $N = 10^4$ permanece um desafio de engenharia que requer otimizações de armazenamento esparsas. A camada diferenciável (implementação JAX) abre caminho para integração com aprendizado neural preservando as garantias algébricas.

Disponibilidade de Dados e Código

Todos os dados experimentais, scripts de análise e código de implementação estão disponíveis no repositório do projeto. Resultados brutos são fornecidos em formato JSON (`experiments/results_phase2.json`, `experiments/results_phase3.json`).

References

- [1] McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. *The Psychology of Learning and Motivation*, 24, 109–165.
- [2] French, R. M. (1999). Catastrophic forgetting in connectionist networks. *Trends in Cognitive Sciences*, 3(4), 128–135.
- [3] Sukhbaatar, S., Weston, J., & Fergus, R. (2016). End-to-end memory networks. *Advances in Neural Information Processing Systems*, 28.
- [4] Bordes, A., Usunier, N., Garcia-Durán, A., Weston, J., & Yakhnenko, O. (2013). Translating embeddings for modeling multi-relational data. *Advances in Neural Information Processing Systems*, 26.
- [5] Graves, A., Wayne, G., Reynolds, M., et al. (2016). Hybrid computing using a neural network with dynamic external memory. *Nature*, 538(7626), 471–476.
- [6] Foster, J. N., Greenwald, M. B., Moore, J. T., Pierce, B. C., & Schmitt, A. (2007). Combinators for bidirectional tree transformations: A linguistic approach to the view-update problem. *ACM Transactions on Programming Languages and Systems*, 29(3), 17.
- [7] Kirkpatrick, J., Pascanu, R., Rabinowitz, N., et al. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521–3526.
- [8] Packer, C., Wooders, S., Lin, K., et al. (2023). MemGPT: Towards LLMs as operating systems. arXiv preprint arXiv:2310.08560.
- [9] Park, J. S., O’Brien, J. C., Cai, C. J., et al. (2023). Generative agents: Interactive simulacra of human behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, Article 2.
- [10] Bulatov, A., Kuratov, Y., & Burtsev, M. (2022). Recurrent memory transformer. arXiv preprint arXiv:2207.06881.
- [11] Ramsauer, H., Schäfl, B., Lehner, J., et al. (2021). Hopfield networks is all you need. *International Conference on Learning Representations*.

A Detalhes de Implementação

A álgebra da memória é implementada em Python (pacote `memory_algebra`) com os seguintes módulos:

- `core.py`: `MemoryObject`, `compose`, `quotient`, `retrieve`, `retract`, `transform`
- `diff.py`: Álgebra diferenciável (JAX) com amostragem de arestas Gumbel-Softmax
- `metric.py`: Distância semântica híbrida d_s com pesos adaptativos ao contexto

- `lens.py`: Operações de lente `get/put`
- `stability.py`: Operador de poda Π_C
- `baselines.py`: Implementação da baseline LSTM

A validação de ground truth categórico utiliza Catlab.jl 0.15 (Julia) com verificações `is_isomorphic` em diagramas de pushout.

B Métodos Estatísticos

- Todos os experimentos utilizam seeds aleatórias independentes (50 para Fase 2A, 30 para Fase 3).
- Significância estatística: teste Mann–Whitney U unilateral (não-paramétrico, amostras independentes), testando se a álgebra tem distância final menor.
- Intervalos de confiança: Bootstrap (95%).
- Tamanhos de efeito reportados como diferenças brutas nas taxas de sucesso.